The Predictive Paradigm

Machine Learning

Ignacio Sarmiento-Barbieri

Universidad de La Plata

Agenda

1. ¿Qué entendemos por Big Data y ML?
2. Sobre el curso
3. Getting serious about prediction
4. Generalization. Out-of-sample Performance
5. Review

Agenda

1. ¿Qué entendemos por Big Data y ML?
2. Sobre el curso
3. Getting serious about prediction
4. Generalization. Out-of-sample Performance
5. Review

¿Qué entendemos por Big Data y ML?

- ¿Que es Big Data?
  - Big n, es solo parte de la historia
  - Big también es big k, muchos covariates, a veces $n << k$
  - Vamos a entender Big también como datos que no surgen de fuentes tradicionales (cuentas nac., etc)
    - Datos de la Web, Geográficos, etc.
- Machine Learning
  - Cambio de paradigma de estimación a predicción

Agenda

1. ¿Qué entendemos por Big Data y ML?
   - Prediction vs Causality
   - ¿Qué es la máquina de aprender?
   - ML Tasks

Prediction vs Causality

- Empirical policy research often focuses on causal inference.
- Since policy choices seem to depend on understanding the counterfactual there's a tight link
- While this link holds in many cases, there are also many policy applications where causal inference is not central, or even necessary.

The Causal Paradigm

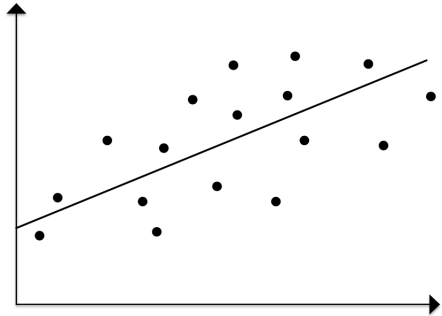
$$y = f(X) + u \tag{1}$$

- Interest lies on inference
- "Correct" $f()$ to understand how y is affected by X
- Model: Theory, experiment
- Hypothesis testing (std. err., tests)

Prediction vs. Causality: Target

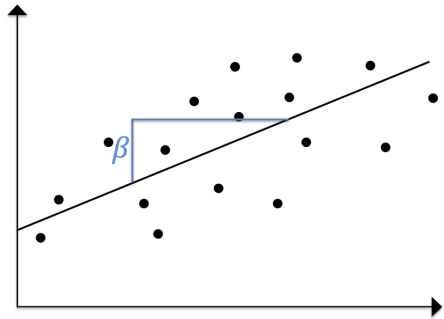
$$y = f(x) + \epsilon \tag{2}$$

$$y = \alpha + \beta x + \epsilon \tag{3}$$



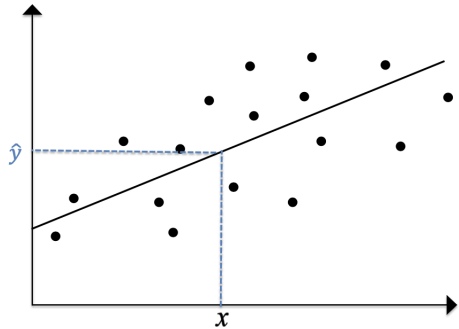
Prediction vs. Causality: Target

$$y = \alpha + \beta x + \epsilon \tag{4}$$



Prediction vs. Causality: Target

$$y = \underbrace{\alpha + \beta x}_{\hat{y}} + \epsilon \tag{5}$$



Agenda

1. ¿Qué entendemos por Big Data y ML?
   - Prediction vs Causality
   - ¿Qué es la máquina de aprender?
   - ML Tasks

¿Qué es la máquina de aprender?

Aprendizaje de máquinas es todo sobre predicción

- El aprendizaje de máquinas es una rama de la estadística y la informática , encargada de desarrollar algoritmos para predecir los resultados y a partir de las variables observables X.
- La parte de aprendizaje proviene del hecho de que no especificamos cómo exactamente la computadora debe predecir y a partir de X.
- Esto queda como un problema empírico que la computadora puede ”aprender”.
- En general, esto significa que nos abstraemos del modelo subyacente, el enfoque es muy pragmático

¿Qué es la máquina de aprender?

Aprendizaje de máquinas es todo sobre predicción

- El aprendizaje de máquinas es una rama de la estadística y la informática , encargada de desarrollar algoritmos para predecir los resultados y a partir de las variables observables X.
- La parte de aprendizaje proviene del hecho de que no especificamos cómo exactamente la computadora debe predecir y a partir de X.
- Esto queda como un problema empírico que la computadora puede ”aprender”.
- En general, esto significa que nos abstraemos del modelo subyacente, el enfoque es muy pragmático

“Whatever works, works....”

“Whatever works, works....”



“Whatever works, works....”????

- En muchas aplicaciones, los científicos de datos pueden aplicar con éxito las técnicas ML con poco conocimiento del dominio del problema.
- Por ejemplo, el sitio web Kaggle organiza concursos de predicción (`www.kaggle.com/competitions`) en los que un patrocinador proporciona un conjunto de datos y los concursantes de todo el mundo pueden enviar entradas, a menudo prediciendo con éxito a pesar del contexto limitado sobre el problema.

“Whatever works, works....”????

- Sin embargo, cuando las aplicaciones ML se utilizan ”off the shelf” sin comprender los supuestos subyacentes o garantizar que se cumplan condiciones básicas las conclusiones pueden verse comprometidas. (Athey, 2017)
- Una pregunta más profunda (y dificil?) se refiere a si un problema dado se puede resolver usando solo técnicas de predicción, o si se requieren enfoques estadísticos para estimar el efecto causal de una intervención.

“Whatever works, works....”????

La primera victoria y derrota de ML

- Contexto ¿similar? al de 2020: en 2009 una epidemia respiratoria en curso
- En EEUU la forma de monitorear es a través de reportes de la CDC
- La CDC agrega a nivel de región y a nivel nacional
- Todo esto llevaba aproximadamente 10 días $\rightarrow$ demasiado tiempo para una epidemia

Policy Prediction Problems

Google se ha unido a la conversación

- Google propuso un mecanismo ingenioso: **Google Flu Trends**
- Punto de partida:
  - Proporción de visitas semanales por enfermedad tipo influenza (ILI)
  - 9 regiones: 128 semanas válidas por región para selección de consultas y 42 semanas adicionales para validación final.
  - Los datos oficiales llegaban con un rezago de una a dos semanas.
- Google cruzó estos datos con las búsquedas de los usuarios
- Con estos datos, construyeron un modelo para predecir intensidad de gripe

Policy Prediction Problems

Google se ha unido a la conversación

- ¿Un sólo modelo?

Policy Prediction Problems

Google se ha unido a la conversación

- ¿Un sólo modelo?
- Los investigadores estimaron **450 millones** de modelos para evaluar consultas candidatas.
- Seleccionaron 45 consultas y estimaron la proporción de visitas médicas por enfermedad tipo influenza (ILI).
- El sistema ofrecía estimaciones casi en tiempo real, inicialmente por regiones de EE. UU.
- Las estimaciones tenían cerca de un día de rezago, frente a 1–2 semanas en los reportes tradicionales.

Policy Prediction Problems

Google se ha unido a la conversación

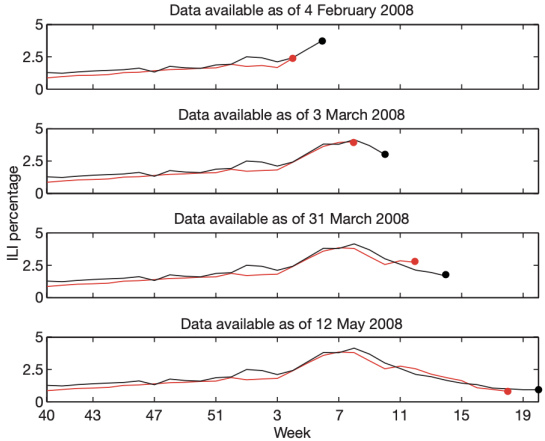


Figure 3 | ILI percentages estimated by our model (black) and provided by the CDC (red) in the mid-Atlantic region, showing data available at four points in the 2007-2008 influenza season. During week 5 we detected a sharply increasing ILI percentage in the mid-Atlantic region; similarly, on 3

Policy Prediction Problems

El rey ha muerto, larga vida al rey

- ¿Qué tienen en común Google Flu y Elvis?
  - Abanderados de la revolución
  - Definió y redefinió las reglas sistemáticas para hallar la solución a un problema
  - Éxito rotundo → Publicación en Nature!
    https://www.nature.com/articles/nature07634
  - Pero como a Elvis el éxito fue efímero
  - El modelo inicial no detectó la primera ola de H1N1 de 2009; versiones posteriores sobreestimaron la actividad gripal en 2012–2013.
  - Google dejó de publicar estimaciones nuevas de Flu Trends en agosto de 2015; las series históricas permanecen disponibles.
  - Google anunció en 2015 que compartiría señales agregadas con centros de investigación y salud pública.

Agenda

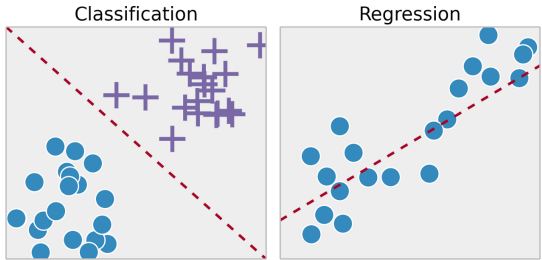
1. ¿Qué entendemos por Big Data y ML?
   - Prediction vs Causality
   - ¿Qué es la máquina de aprender?
   - ML Tasks

ML branches

- ML tasks can (¿?) be divided into two main branches:
  1. Supervised Learning

ML branches

- Supervised Learning
  - for each predictor x_i a 'response' is observed y_i.
  - everything we have done in econometrics is supervised



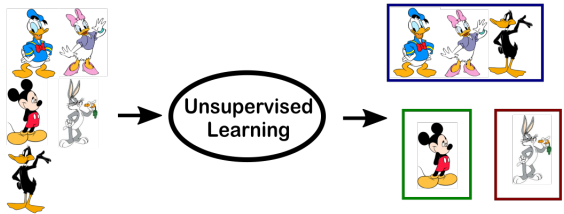
Source: shorturl.at/opqKT

ML branches

- ML tasks can (¿?) be divided into two main branches:
  1. Supervised Learning
  2. Unsupervised Learning

ML branches

- Unsupervised Learning
  - observed x_i but no response.
  - example: cluster analysis



Source: shorturl.at/opqKT

Agenda

1. ¿Qué entendemos por Big Data y ML?
2. Sobre el curso
3. Getting serious about prediction
4. Generalization. Out-of-sample Performance
5. Review

Agenda

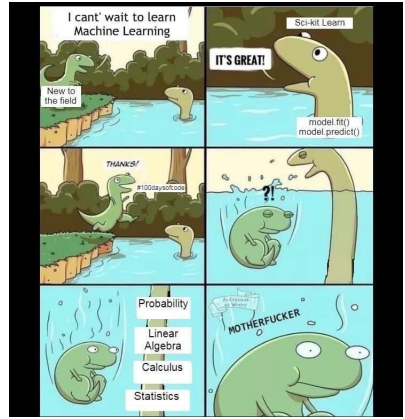
2. Sobre el curso
   - Aspectos generales
   - About LLMs, Agents, and so on
     - Ganancias y Peligros

Sobre el curso

- El aprendizaje automático en economía es muy nuevo y dinámico.
  - Las similitudes con la econometría plantea interrogantes:
    - ¿Estos algoritmos están simplemente aplicando técnicas estándar a nuevos y grandes conjuntos de datos?
    - Si hay herramientas empíricas fundamentalmente nuevas, ¿cómo encajan con lo que conocemos?
    - Como economistas empíricos, ¿cómo podemos utilizarlas?
- Estas clases darán un *"snapshot"* de este campo en evolución.
- Estudiaremos ML a través de ejemplos, centrándonos en algunas aplicaciones y algoritmos de ML.

Lenguajes

- Estadística y Econometría
- Inglés
- Código
  - Elijan el que quieran:
    - `R`, `Python`, o cualquier otro
    - no hay restricción
    - yo usaré `R`
  - Agentes son bienvenidos, con caveats (more below)
- Materiales en link
- Evaluación: Proyecto Final



Agenda

2. Sobre el curso
   - Aspectos generales
   - About LLMs, Agents, and so on
     - Ganancias y Peligros

La función de producción humano e IA

$$Q = f(H, M)$$

- H = tiempo humano
- M = tiempo de máquina

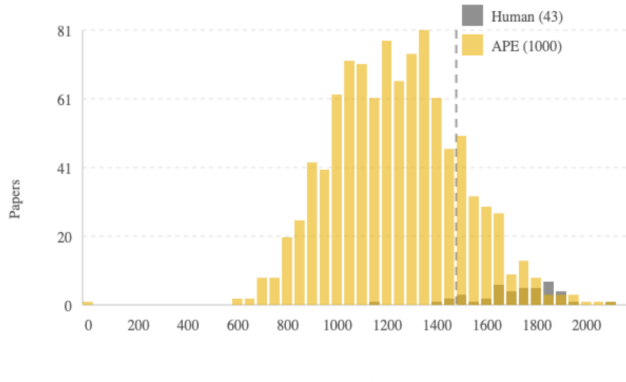
La pregunta no es *si* usar M. Es cuánto H utilizamos intencionalmente.

La investigación autónoma ya estaba aquí

El **Project APE** del Social Catalyst Lab ha producido más de **1,000** artículos empíricos de política generados de forma autónoma.

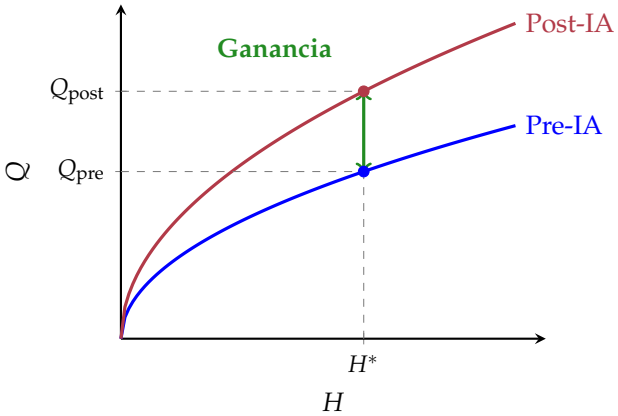
Agentes que:

- extraen datos públicos
- corren diseños empíricos
- escriben artículos completos



Artículos de APE vs. artículos humanos.

Caso I: mantener el esfuerzo constante, ganancia asegurada

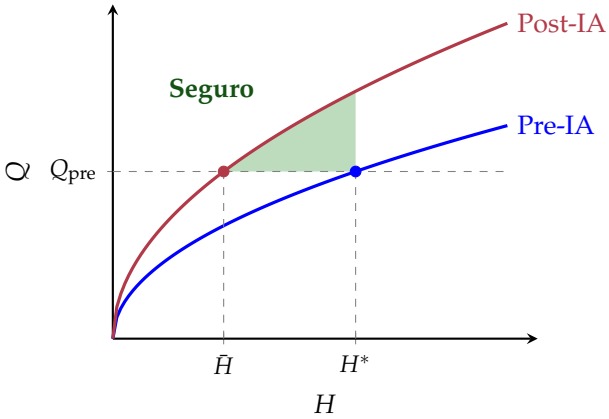


Mantener H^* igual. Más y mejor trabajo en las mismas horas.

- Mayores ganancias en producto.
- Capital humano preservado.

Esto requiere no tomar todo el ahorro de tiempo.

Caso II: ahorrar tiempo e igual producto

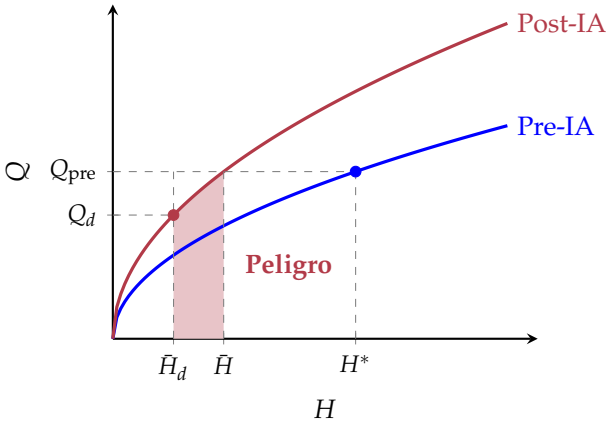


Recortar horas, pero quedarnos en la zona verde. Mientras $H > \bar{H}$, el producto se mantiene por encima de la línea base.

- Ahorro de tiempo moderado.
- Aún una ganancia neta en producto.

Algo de holgura está bien. La curva subió lo suficiente para absorberla.

Caso III: la zona peligrosa



La zona de peligro. La depreciación de habilidades sin el esfuerzo para mantener $H > \bar{H}$ implica $Q_{\text{post}} < Q_{\text{pre}}$.

- Peor que antes de la IA.

El punto no es evitar el ahorro de tiempo. El punto es ser intencional.

No confíes en nada y verifícalo todo

The New York Times

A.I. 'Hallucinations' Created Errors in Court Filing, Top Law Firm Says

Sullivan & Cromwell apologized for submitting a court document that had fake citations created by artificial intelligence.

Listen · 4:38 min Share full article 426



Lawyers for Sullivan & Cromwell apologized for submitting a court filing that had fake citations created by artificial intelligence. John Taggart for The New York Times

By Santul Nerkar

April 21, 2026

No confíes en nada y verifícalo todo

Lo llamativo es que la capacitación en IA de la firma *ya* incluía la regla:

No confíes en nada
Verifícalo todo

La regla era correcta. El flujo de trabajo aun así falló.

Producción y verificación son tareas distintas

Imaginen su trabajo como una serie de carpetas llenas de archivos que manipulas en dos tareas distintas:

Producción

Generar borradores, código, tablas, simulaciones, resúmenes de literatura, slides y versiones alternativas.

Verificación

Saber si el resultado es verdadero, fiel, correctamente estimado y digno de creerse.

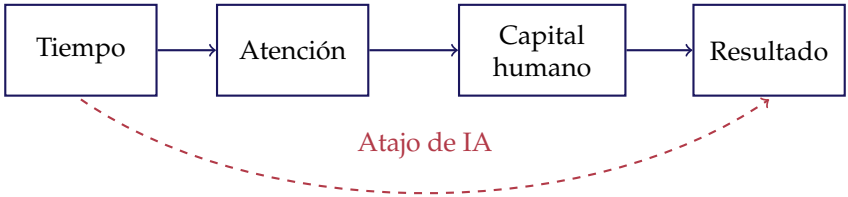
Históricamente venían empaquetadas juntas. Los agentes de IA las están separando.

La ventaja comparativa en producción varía entre individuo y cambia con el tiempo. Pero el camino de la idea al producto final está siendo reconfigurado por los agentes.

Ganancias y riesgos

Las ganancias son reales.

El riesgo también es real: si los agentes nos permiten saltarnos la atención, podríamos dejar de construir el capital humano necesario para juzgar el resultado.

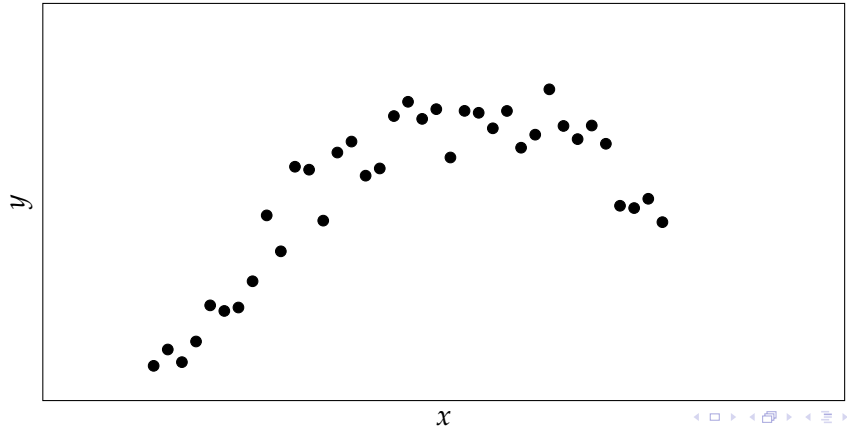


Agenda

1. ¿Qué entendemos por Big Data y ML?
2. Sobre el curso
3. Getting serious about prediction
4. Generalization. Out-of-sample Performance
5. Review

Getting serious about prediction

$$Y = f(X) + u \tag{6}$$



How do we measure: "Whatever works, works...."?

Decision Theory

- We need a bit of theory to give us a framework for choosing f
- A decision theory approach involves an **action space** $\mathcal{A}$
- The **action space** $\mathcal{A}$ specify the possible "actions we might take"
- Some examples

Table 1: Action Spaces

Inference	Action Space
Estimation	$\mathcal{A} = \Theta$
Hyp. Testing	$\mathcal{A} = \{Reject \vert Accept\, H_0\}$
Prediction	$\mathcal{A} = \hat{Y}$

How do we measure: "Whatever works, works...."?

Decision Theory

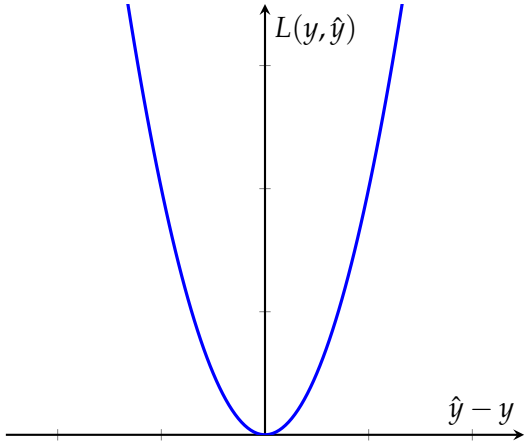
- The loss function specifies the penalty for taking a particular action

$$L : \Theta \times \mathcal{A} \to [0, \infty] \tag{7}$$

- Loss is minimum if the action is correct

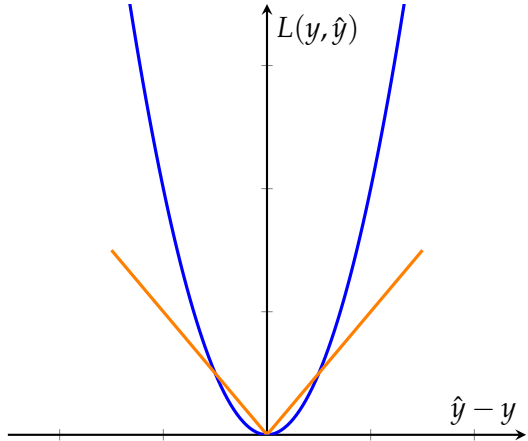
How do we measure: “Whatever works, works....”?

Decision Theory: Loss Functions



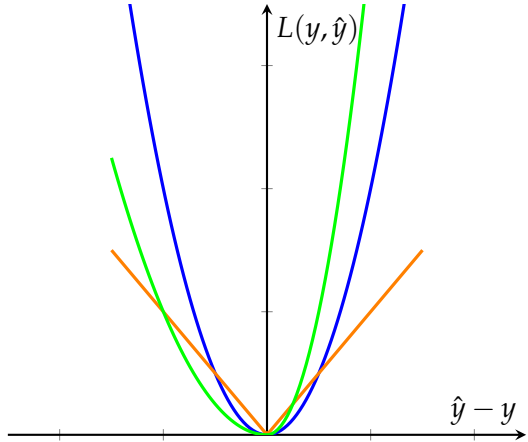
How do we measure: “Whatever works, works....”?

Decision Theory: Loss Functions



How do we measure: “Whatever works, works....”?

Decision Theory: Loss Functions



How do we measure: "Whatever works, works...."?

Decision Theory: Risk Function

- In a decision theoretic analysis, the quality of an decision is quantified by its risk function,
- For example, in econometrics, for an estimator $\hat{\beta}(X)$ of β, the risk function is

$$R(\beta, \hat{\beta}(X)) = E(L(\beta, \hat{\beta}(X))) \tag{8}$$

- at a given β, the risk function is the average loss that will be incurred if the estimator $\hat{\beta}(X)$ is used

How do we measure: "Whatever works, works...."?

Prediction in the Population

Before any data: what is the best we could do if we knew the full joint distribution?

- We observe random variables $(Y, X) \sim F$.
- A predictor is a function
$$f : \mathcal{X} \to \mathbb{R}.$$
- The population risk under squared loss is
$$R(f) = \mathbb{E}\left[(Y - f(X))^2\right].$$
- The best predictor solves
$$f^* = \arg\min_f R(f).$$

Optimal Predictor Under Squared Loss

- Start from
$$R(f) = \mathbb{E}\left[(Y - f(X))^2\right].$$
- Writing the expectation as an integral,
$$R(f) = \int_{\mathcal{X}} \int_{\mathcal{Y}} (y - f(x))^2 f_{X,Y}(x,y)\, dy\, dx.$$
- Using
$$f_{X,Y}(x,y) = f_{Y|X}(y \mid x) f_X(x),$$
- we get
$$R(f) = \int_{\mathcal{X}} \left[\int_{\mathcal{Y}} (y - f(x))^2 f_{Y|X}(y \mid x)\, dy \right] f_X(x)\, dx.$$

Pointwise Minimization

- For each fixed x, minimize

$$\int_{\mathcal{Y}} (y - f(x))^2 f_{Y|X}(y \mid x)\, dy.$$

- The first-order condition is

$$-2 \int_{\mathcal{Y}} (y - f(x)) f_{Y|X}(y \mid x)\, dy = 0.$$

- Therefore,

$$f^*(x) = \int_{\mathcal{Y}} y f_{Y|X}(y \mid x)\, dy = \mathbb{E}[Y \mid X = x].$$

- So,

$$f^*(X) = \mathbb{E}[Y \mid X].$$

- Second-order condition?

From Best Predictor to Linear Regression

- The unrestricted best predictor is

$$f^*(X) = \mathbb{E}[Y \mid X].$$

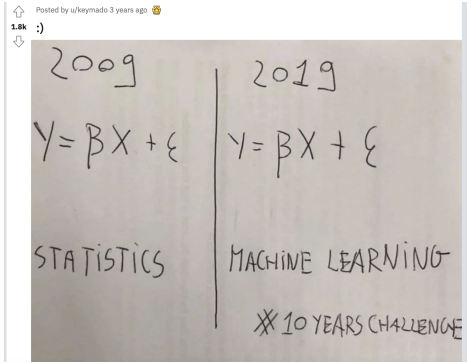
- But $\mathbb{E}[Y \mid X]$ is unknown.

From Best Predictor to Linear Regression

- The unrestricted best predictor is

$$f^*(X) = \mathbb{E}[Y \mid X].$$

- But $\mathbb{E}[Y \mid X]$ is unknown.



Source: Reddit, u/keymado.

Best Linear Predictor

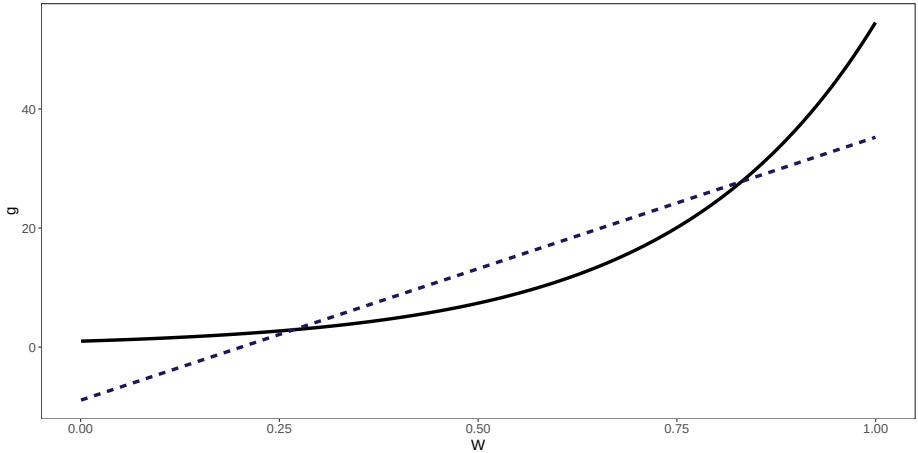
- Linear regression restricts the predictor to be linear in the parameters:

$$f(X) = X'\beta.$$

- This is still flexible: X may include transformations, interactions, and polynomials.

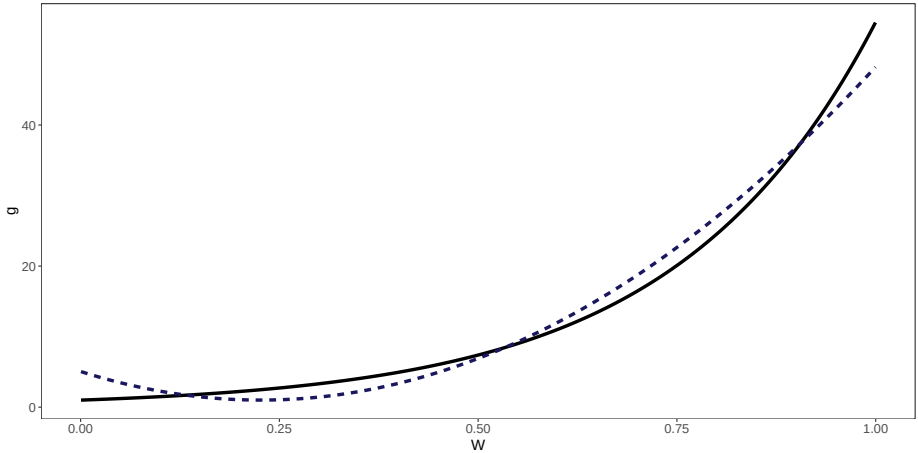
Best Linear Predictor

The right functional forms



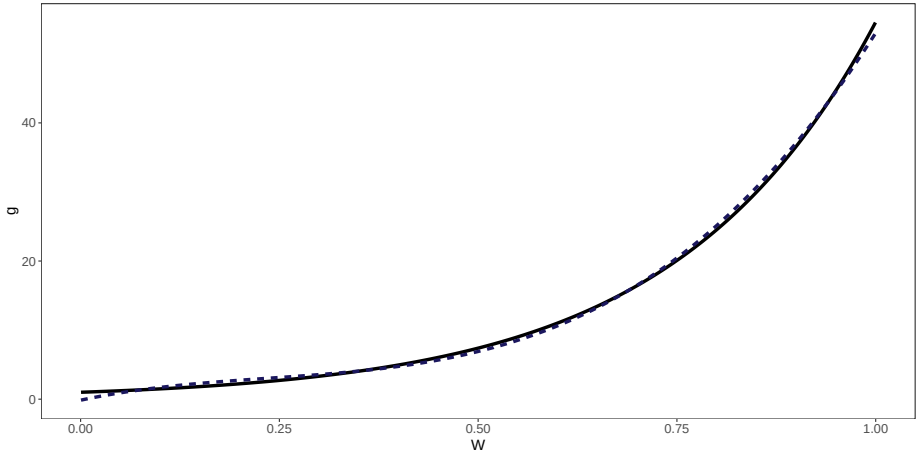
Best Linear Predictor

The right functional forms



Best Linear Predictor

The right functional forms



Best Linear Predictor

- The best linear predictor (β^*) solves

$$\beta^* = \arg\min_{\beta} \mathbb{E}\left[(Y - X'\beta)^2\right].$$

- Thus, linear regression is the best approximation to

$$\mathbb{E}[Y \mid X]$$

within the class of functions that are linear in the parameters.

Population vs Sample

- In the population:

$$\beta^* = \arg\min_{\beta} \mathbb{E}\left[(Y - X'\beta)^2\right].$$

- In the sample:

$$\hat{\beta} = \arg\min_{\beta} \frac{1}{n}\sum_{i=1}^{n}(Y_i - X_i'\beta)^2.$$

- OLS is the sample analogue of the best linear predictor.

Agenda

1. ¿Qué entendemos por Big Data y ML?
2. Sobre el curso
3. Getting serious about prediction
4. Generalization. Out-of-sample Performance
5. Review

Generalization Overview

- In ML we care in out-of-sample prediction
- Generalization refers to a model's performance on unseen data.
- The ultimate goal is **not** minimizing the in-sample loss, but achieving low error out-of-sample on unseen data.

Training and Test Loss

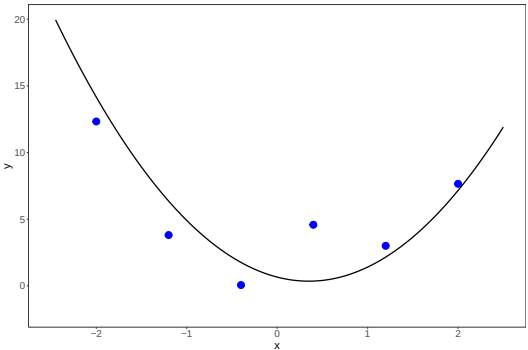
- Unseen data is typically refered as **test data**,
- While the sample data is called the **training data**.
- The expected loss over the test distribution is called the test loss.
- Test loss is defined as:

$$L(\theta) = \mathbb{E}_{(X,y)\sim F}[(y - f_\beta(X))^2]$$

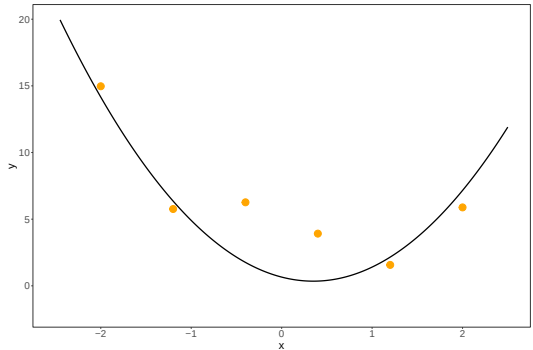
Overfitting and Underfitting

- Successfully minimizing training error does not always result in a small test error.
- A model is said to overfit if it predicts accurately on training data but poorly on test (unseen) data.
- A model underfits if its training error is relatively large, which usually means test error is also large.
- Understanding overfitting and underfitting helps in choosing appropriate model parameterizations.

Overfitting and Underfitting. Bias-Variance Tradeoff



(a) Training Data



(b) Testing Data

Overfitting and Underfitting. Bias-Variance Tradeoff

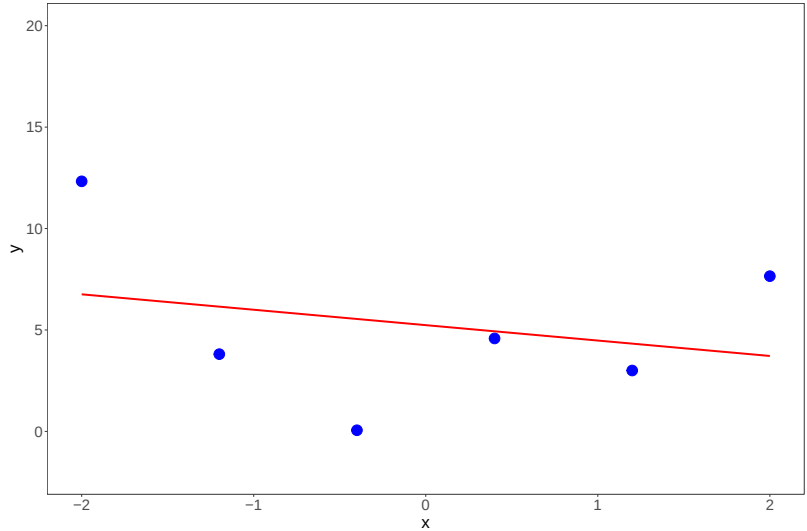
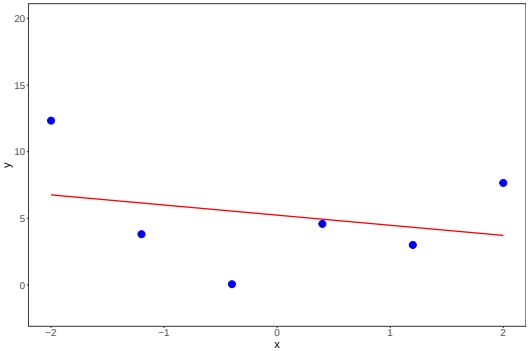


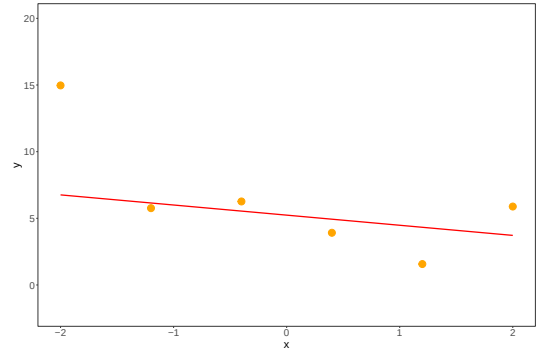
Figure 2: Training Data

Overfitting and Underfitting. Bias-Variance Tradeoff

Out-of-Sample Performance



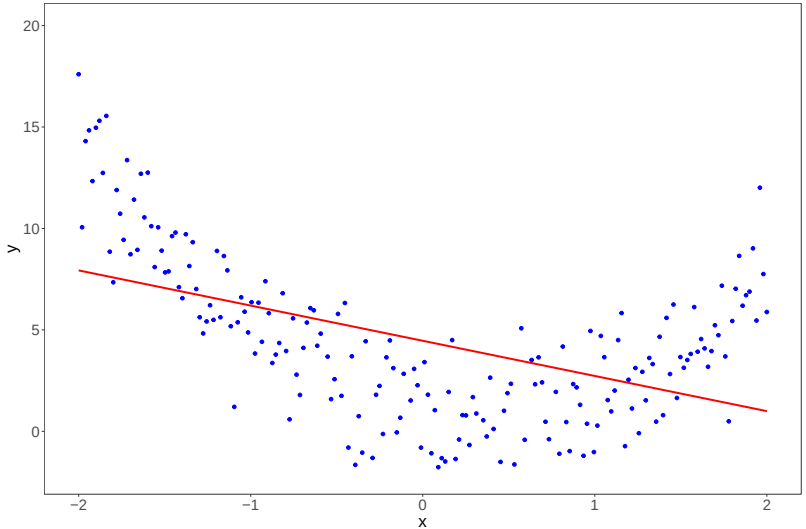
(a) Training Data



(b) Testing Data

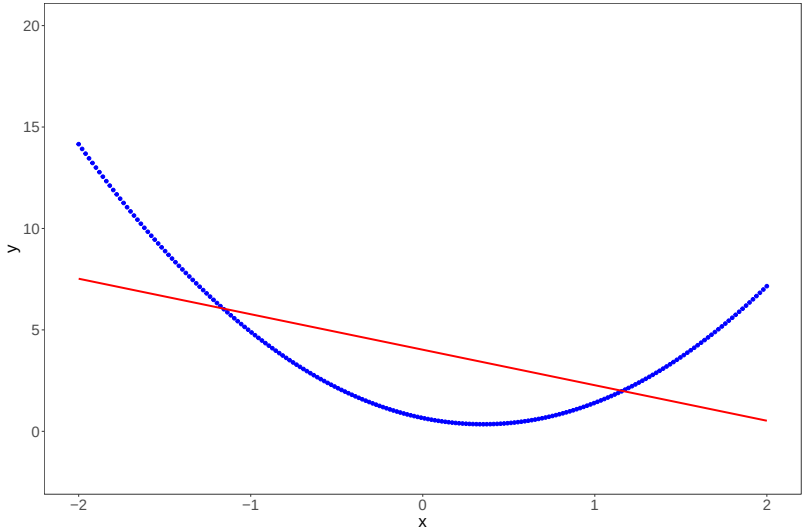
Overfitting and Underfitting. Bias-Variance Tradeoff

More data?



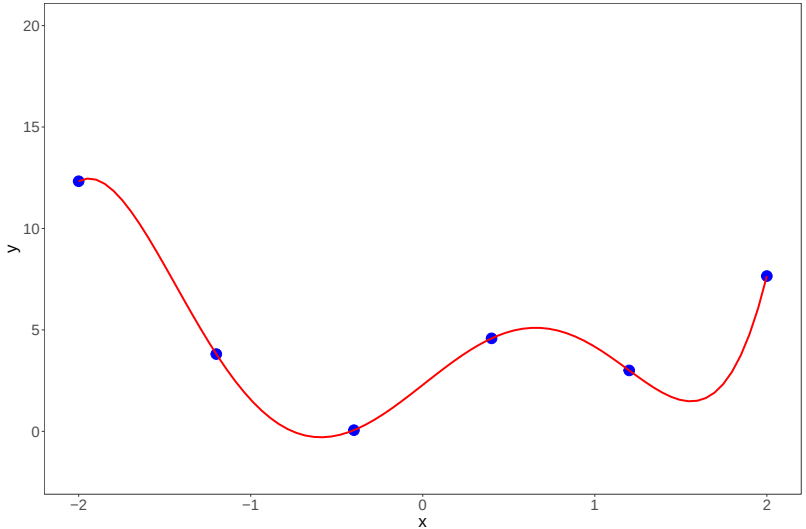
Overfitting and Underfitting. Bias-Variance Tradeoff

Noiseless data?



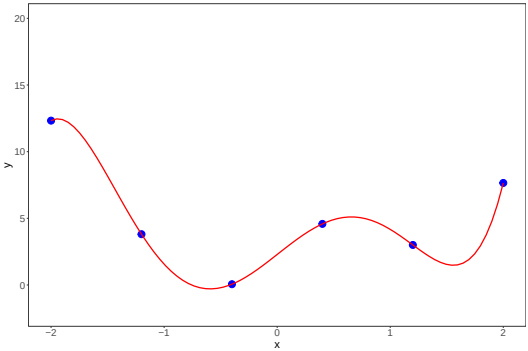
Overfitting and Underfitting. Bias-Variance Tradeoff

More Complex Model

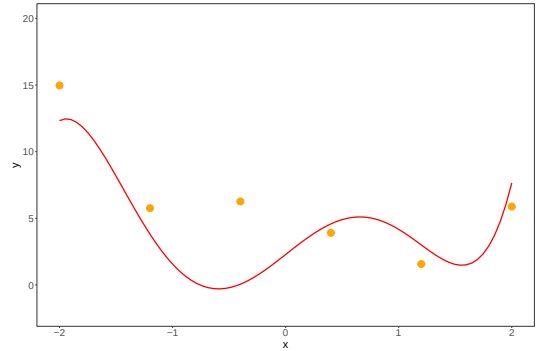


Overfitting and Underfitting. Bias-Variance Tradeoff

Out-of-Sample Performance



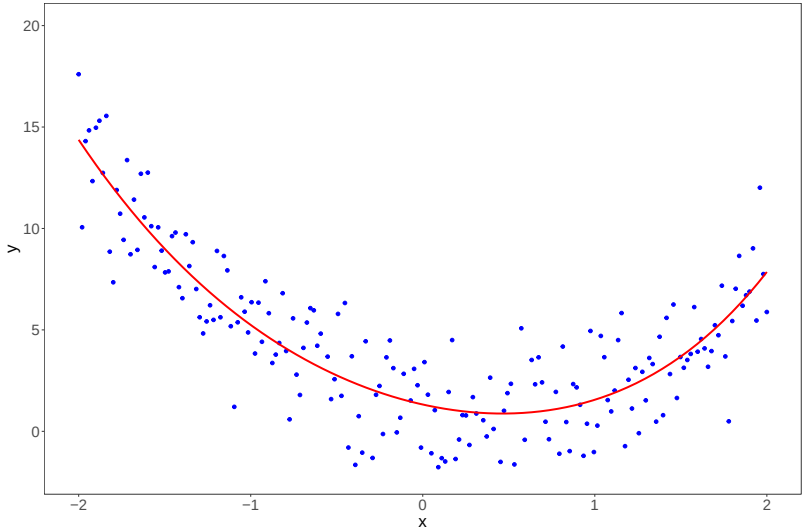
(a) Training Data



(b) Testing Data

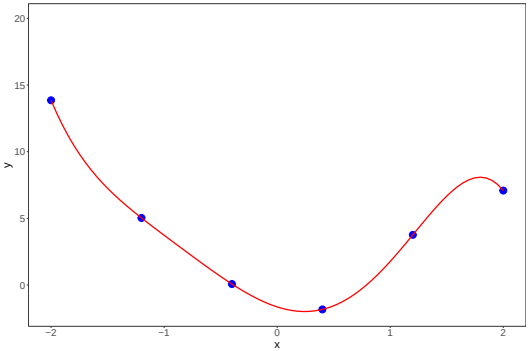
Overfitting and Underfitting. Bias-Variance Tradeoff

More Data

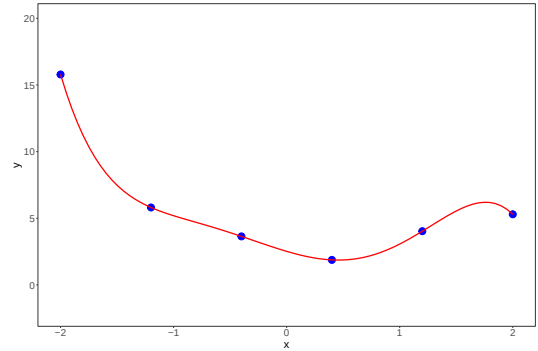


Overfitting and Underfitting. Bias-Variance Tradeoff

Variance



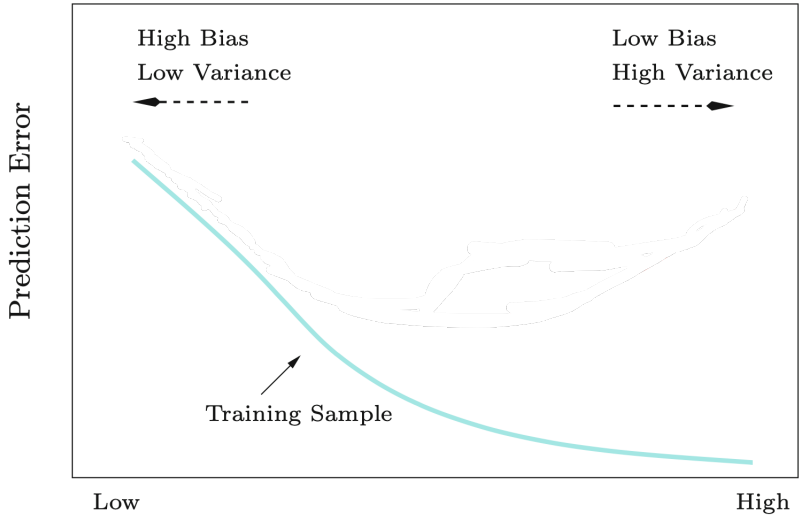
(a) Training Data 2



(b) Training Data 3

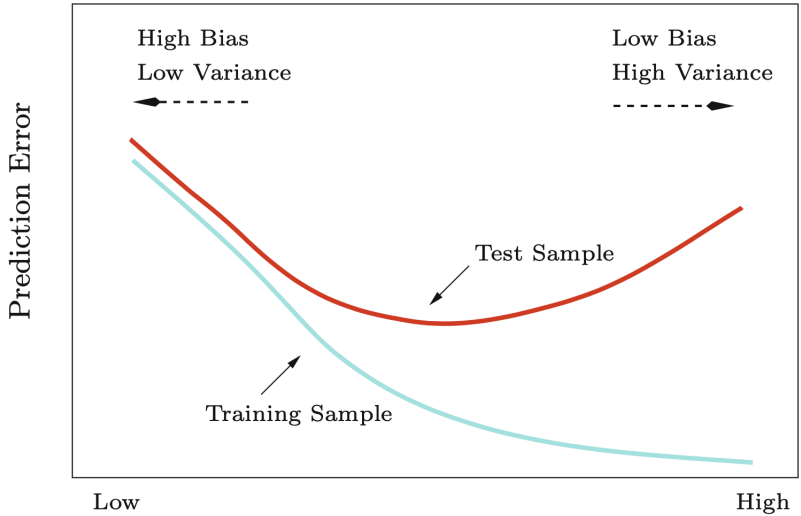
Overfitting and Underfitting. Bias-Variance Tradeoff

In-Sample Prediction and Overfit



Overfitting and Underfitting. Bias-Variance Tradeoff

Out-of-Sample Prediction and Overfit



Mathematical Decomposition for Regression

- Consider a training dataset $S = \{x^{(i)}, y^{(i)}\}_{i=1}^{n}$ where

$$y^{(i)} = f^*(x^{(i)}) + \xi^{(i)} \tag{9}$$

  with $\xi^{(i)}$ $E(\xi^{(i)}) = 0, Var(\xi^{(i)}) = \sigma^2)$.
- Train a model on the dataset S, denoted by $\hat{f}_S$.
- Take a test point (x, y) where

$$y = f^*(x) + \xi \tag{10}$$

  and ξ, $E(\xi) = 0, Var(\xi) = \sigma^2)$.
- The expected test error is given by:

$$\text{MSE}(x) = \mathbb{E}_{S,\xi}[(y - \hat{f}_S(x))^2]$$

Mathematical Decomposition for Regression

$$
\begin{aligned}
\mathrm{MSE}(x) &= \mathbb{E}_{S,\xi}\left[(f^*(x) + \xi - \hat{f}_S(x))^2\right] \\
&= \mathbb{E}_S\left[(f^*(x) - \hat{f}_S(x))^2\right] + 2\,\mathbb{E}_{S,\xi}\left[\xi(f^*(x) - \hat{f}_S(x))\right] + \mathbb{E}[\xi^2] \\
&= \underbrace{\mathbb{E}_S\left[(f^*(x) - \hat{f}_S(x))^2\right]}_{\text{Error reducible}} + \underbrace{\sigma^2}_{\text{Error irreducible}}
\end{aligned}
$$

Mathematical Decomposition for Regression

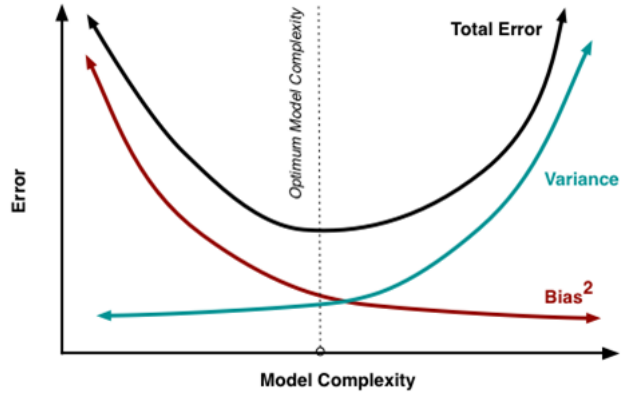
- Podemos descomponer el error reducible

$$\begin{aligned}\mathbb{E}_S[(f^*(x) - \hat{f}_S(x))^2] &= \mathbb{E}_S[(f^*(x) - E_S[\hat{f}_S(x)] + E_S[\hat{f}_S(x)] - \hat{f}_S(x))^2] \\ &= \underbrace{(f^*(x) - E_S[\hat{f}_S(x)])^2}_{\text{Bias}(x)^2} + \underbrace{\mathbb{E}_S[(\hat{f}_S(x) - m(x))^2]}_{\text{Var}_S(\hat{f}_S(x))}\end{aligned}$$

- entonces,

$$\text{MSE}(x) = \text{Bias}(x)^2 + \text{Var}_S(\hat{f}_S(x)) + \sigma^2$$

Bias-Variance Tradeoff



Source: https://tinyurl.com/y4lvjxpc

- ML best kept secret: By tolerating some bias we can have significant gains in variance

Agenda

4. Generalization. Out-of-sample Performance
   - Out-of-Sample Performance
   - Cross-Validation

Out-of-Sample Performance

- ¿Cómo seleccionamos el modelo que minimiza el error de predicción esperado fuera de muestra?
- Problema: solo contamos con una muestra de datos y no conocemos el error sobre observaciones futuras.
- Necesitamos estimar el desempeño predictivo fuera de muestra.

Estimación del error fuera de muestra

- Para seleccionar un modelo según su capacidad predictiva, necesitamos estimar su desempeño fuera de muestra.
- Dos estrategias comunes:
  - **Criterios basados en penalizaciones:** combinan el ajuste dentro de muestra con una penalización por complejidad para controlar el sobreajuste. $\Rightarrow$ Penzalización ex post: AIC, BIC, etc.

Estimación del error fuera de muestra

AIC y S(B)IC

- Ambos combinan ajuste dentro de muestra y una penalización por complejidad.

$$AIC(j) = \log\left(\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_{i,j})^2\right) + \frac{2}{n}p_j \tag{11}$$

$$BIC(j) = \log\left(\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_{i,j})^2\right) + \frac{\log(n)}{n}p_j \tag{12}$$

Estimación del error fuera de muestra

- Para seleccionar un modelo según su capacidad predictiva, necesitamos estimar su desempeño fuera de muestra.

- Dos estrategias comunes:
  - **Criterios basados en penalizaciones:** combinan el ajuste dentro de muestra con una penalización por complejidad para controlar el sobreajuste. $\Rightarrow$ Penzalización ex post: AIC, BIC, etc.
  - **Métodos de remuestreo:** estiman el desempeño predictivo utilizando observaciones que no participaron en el ajuste. Ejemplo: cross-validation.

Agenda

4. Generalization. Out-of-sample Performance
   - Out-of-Sample Performance
   - Cross-Validation

Test Error

Cross-Validation



photo from https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/

Agenda

1. ¿Qué entendemos por Big Data y ML?
2. Sobre el curso
3. Getting serious about prediction
4. Generalization. Out-of-sample Performance
5. Review

Review

- This Week:
  - Machine Learning is all about prediction
  - ML targets something different than causal inference, they can complement each other
  - Bias Variance trade-off: tolerating some bias is possible to reduce $V(\hat{f}(X))$ and lower MSE (ML best kept secret)
  - Overfit and Model Selecction
    - AIC y BIC
    - Validation Approach
    - LOOCV
    - K-fold Cross-Validation