Selección de Modelos Lineales y Regularización

Machine Learning

Ignacio Sarmiento-Barbieri

Universidad de La Plata

Agenda

1. Recap: Predicción y Overfit
2. Out-of-Sample Performance
   - Enfoque de Validación
   - LOOCV
   - Validación Cruzada en K Partes
3. Selección de Modelos Lineales
   - Elección del Mejor Conjunto
   - Elección por Pasos
4. Regularización
   - Recap: OLS Mechanics
   - Ridge
   - Lasso
   - $k > n$
   - Ridge and Lasso: Pros and Cons
   - Familia de regresiones penalizadas
   - Elastic Net

Agenda

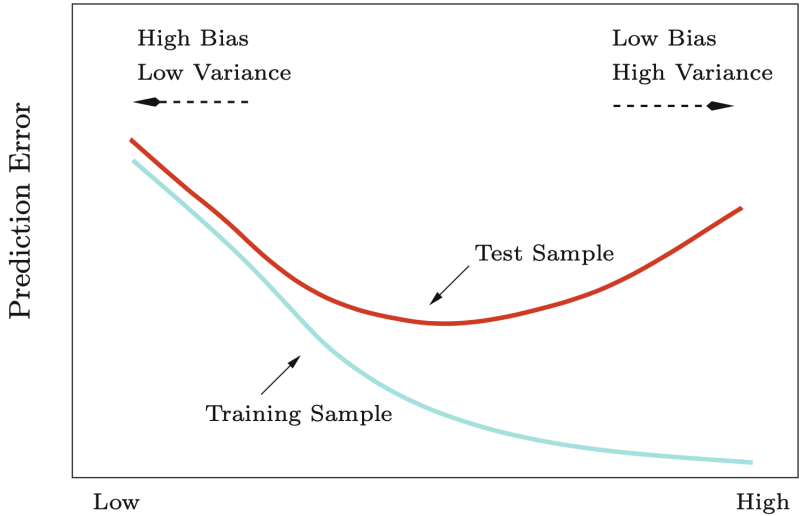
1. Recap: Predicción y Overfit
2. Out-of-Sample Performance
3. Selección de Modelos Lineales
4. Regularización

Overfit y Predicción fuera de Muestra

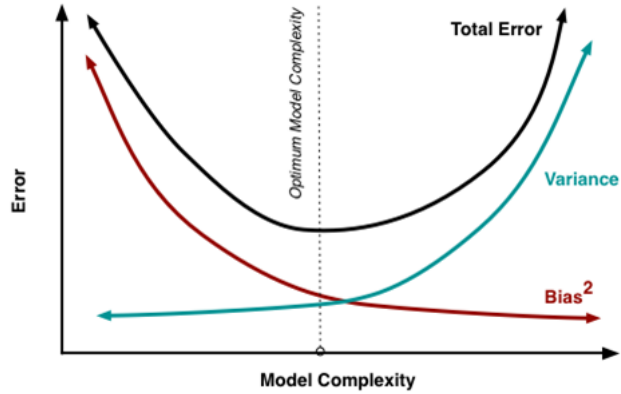
- ML nos interesa la predicción fuera de muestra
- Overfit: modelos complejos predicen bien dentro de muestra, pero tienden a hacer un mal trabajo fuera de muestra

Overfitting and Underfitting. Bias-Variance Tradeoff

Out-of-Sample Prediction and Overfit



Bias-Variance Tradeoff



Source: https://tinyurl.com/y4lvjxpc

- ML best kept secret: By tolerating some bias we can have significant gains in variance

Overfit y Predicción fuera de Muestra

- ML nos interesa la predicción fuera de muestra
- Overfit: modelos complejos predicen bien dentro de muestra, pero tienden a hacer un mal trabajo fuera de muestra
- Hay que elegir el modelo que "mejor" prediga fuera de muestra, i.e., que tenga un menor error fuera de muestra

Overfit y Predicción fuera de Muestra

- ML nos interesa la predicción fuera de muestra
- Overfit: modelos complejos predicen bien dentro de muestra, pero tienden a hacer un mal trabajo fuera de muestra
- Hay que elegir el modelo que "mejor" prediga fuera de muestra, i.e., que tenga un menor error fuera de muestra
- Dos preguntas abiertas
  - ¿Como mido el error de predicción esperado fuera de muestra?

$$\mathbb{E}_{S,\tilde{\xi}}[(y - \hat{f}_S(x))^2]$$

  - ¿Cómo seleccionamos el modelo que minimiza el error de predicción esperado fuera de muestra?

Agenda

1. Recap: Predicción y Overfit
2. Out-of-Sample Performance
3. Selección de Modelos Lineales
4. Regularización

Out-of-Sample Performance

- ¿Como mido el error de predicción esperado fuera de muestra?

$$\mathbb{E}_{S,\xi}[(y - \hat{f}_S(x))^2]$$

- Problema: solo contamos con una muestra de datos y no conocemos el error sobre observaciones futuras.

Estimación del error fuera de muestra

- Dos estrategias comunes:
  - **Criterios basados en penalizaciones:** combinan el ajuste dentro de muestra con una penalización por complejidad para controlar el sobreajuste. $\Rightarrow$ Penzalización ex post: AIC, BIC, etc.

Estimación del error fuera de muestra

AIC y S(B)IC

- Ambos combinan ajuste dentro de muestra y una penalización por complejidad.

$$AIC(j) = \log\left(\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_{i,j})^2\right) + \frac{2}{n}p_j \tag{1}$$

$$BIC(j) = \log\left(\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_{i,j})^2\right) + \frac{\log(n)}{n}p_j \tag{2}$$

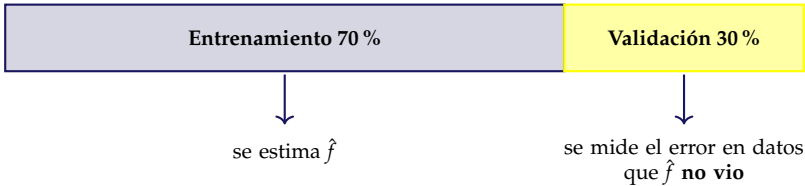
Estimación del error fuera de muestra

- Dos estrategias comunes:
  - **Criterios basados en penalizaciones:** combinan el ajuste dentro de muestra con una penalización por complejidad para controlar el sobreajuste. $\Rightarrow$ Penzalización ex post: AIC, BIC, etc.
  - **Métodos de remuestreo:** estiman el desempeño predictivo utilizando observaciones que no participaron en el ajuste. Ejemplo: cross-validation.

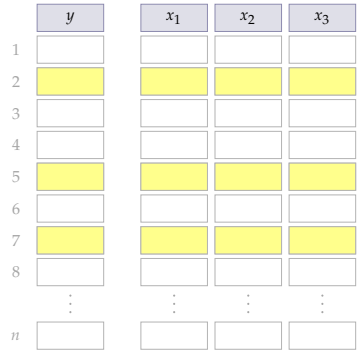
Agenda

2. Out-of-Sample Performance
   - Enfoque de Validación
   - LOOCV
   - Validación Cruzada en K Partes

Enfoque de Validación



Enfoque de Validación



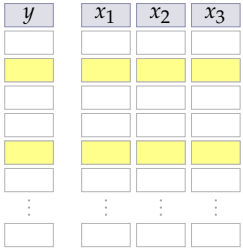
Entrenamiento · 70 % de las filas
estima $\hat{f}$

Validación · 30 %
mide el error

Enfoque de Validación

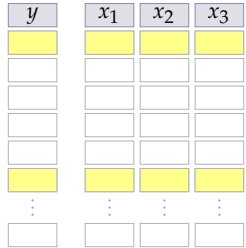
Problema

aleatorización 1



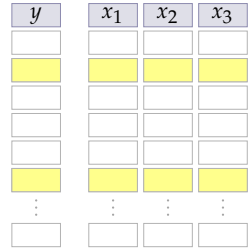
MSE 1

aleatorización 2



MSE 2

aleatorización 3

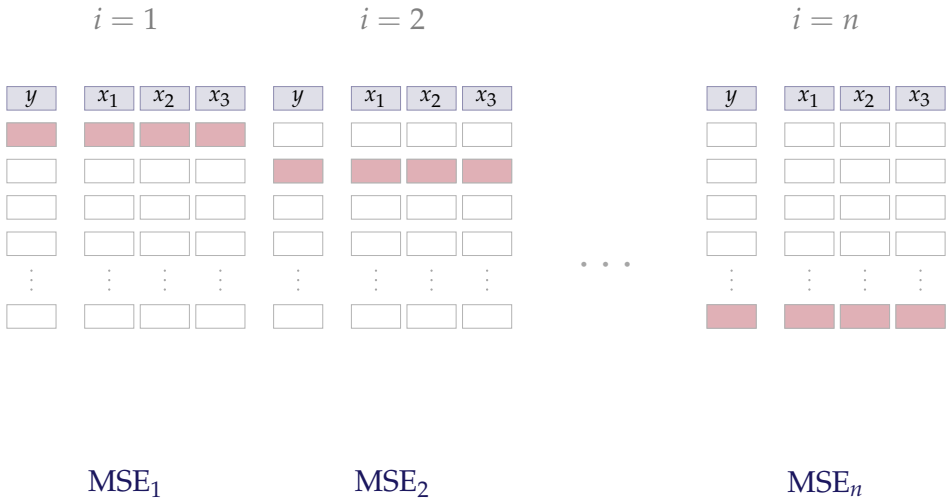


MSE 3

Agenda

2. Out-of-Sample Performance
   - Enfoque de Validación
   - LOOCV
   - Validación Cruzada en K Partes

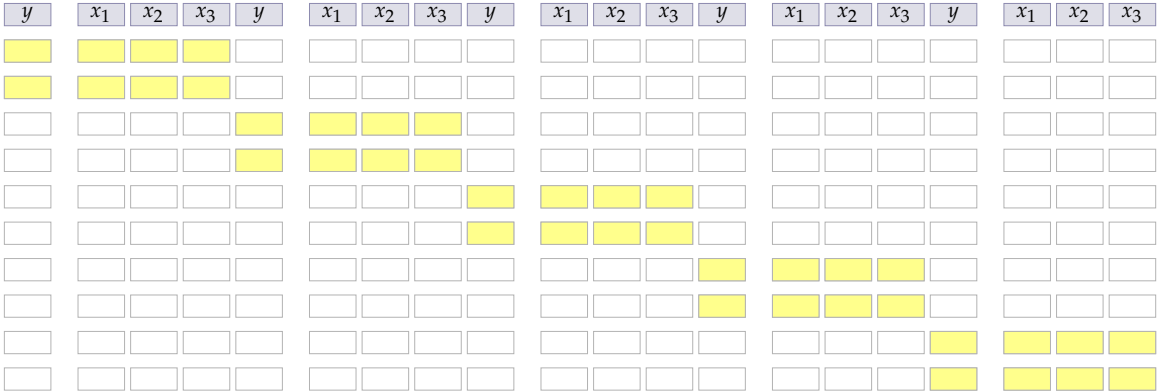
Leave-One-Out Cross Validation



Agenda

2. Out-of-Sample Performance
   - Enfoque de Validación
   - LOOCV
   - Validación Cruzada en K Partes

Validación cruzada en K partes



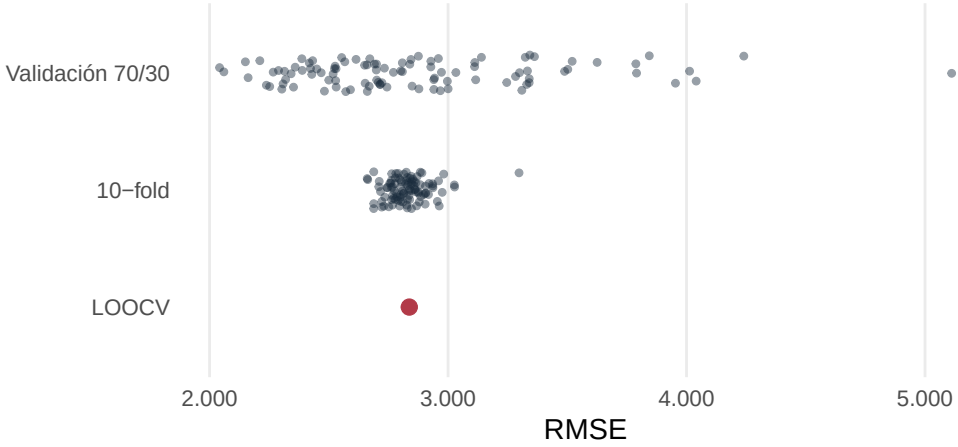
Test Error

Cross-Validation



photo from https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/

Tres métodos



¿Por qué 5 o 10 y no n?

- **Sesgo:** una sola partición entrena con menos datos y *sobre*estima Err **en promedio**. LOOCV entrena con $n - 1$: casi sin sesgo. K-fold queda en el medio
- **Varianza:** LOOCV promedia n modelos entrenados sobre bases casi idénticas $\Rightarrow$ muy correlacionados, y el promedio de cosas correlacionadas no baja mucho la varianza
- Con K-fold los K modelos se parecen menos entre sí

$K = 5$ o $K = 10$: ni el sesgo de una partición ni la varianza de LOOCV.

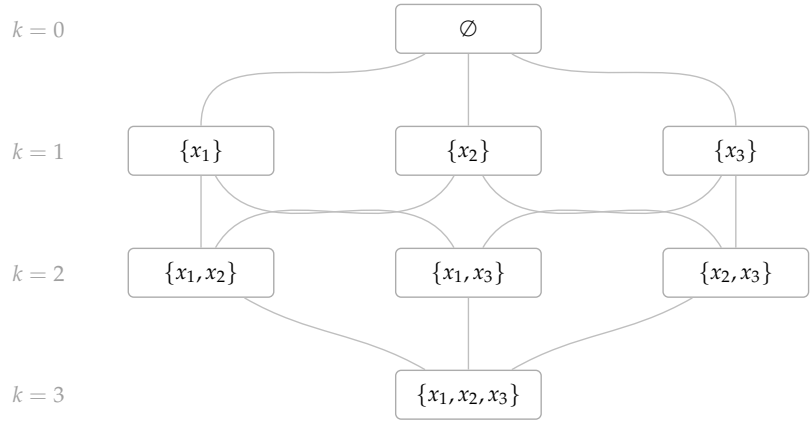
Agenda

1. Recap: Predicción y Overfit
2. Out-of-Sample Performance
3. Selección de Modelos Lineales
4. Regularización

Selección de modelos lineales: motivación

- Tenemos M_k modelos lineales
- Queremos encontrar el que mejor predice fuera de muestra
- Hay distintas formas de enfrentarlo
- Las clásicas
  - Elección del mejor conjunto
  - Elección por pasos
    - Hacia adelante (*forward*)
    - Hacia atrás (*backward*)

Selección de modelos lineales: motivación



Agenda

3 Selección de Modelos Lineales
- Elección del Mejor Conjunto
- Elección por Pasos

Elección del mejor conjunto

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + u$$

1. Estimar ***todos*** los modelos posibles con $k = 0, 1, \ldots, p$ predictores
2. Calcular el error de predicción de cada uno con validación cruzada
3. Quedarse con el de menor error de predicción

Elección del mejor conjunto

Un algoritmo factible

1. Sea M_0 el modelo nulo, sin predictores: predice la media muestral
2. Para $k = 1, 2, \ldots, p$:
   1. Ajustar los $\binom{p}{k}$ modelos con exactamente k predictores
   2. Quedarse con el mejor de esos $\binom{p}{k}$ y llamarlo M_k (mejor = menor SSR)
3. Elegir uno solo entre $M_0, \ldots, M_p$ con **validación cruzada**

Cuántos modelos hay que ajustar

p	Mejor conjunto 2^p
3	8
10	1.024
20	1.048.576
40	1.099.511.627.776

Agenda

3 Selección de Modelos Lineales
- Elección del Mejor Conjunto
- Elección por Pasos

Elección por pasos

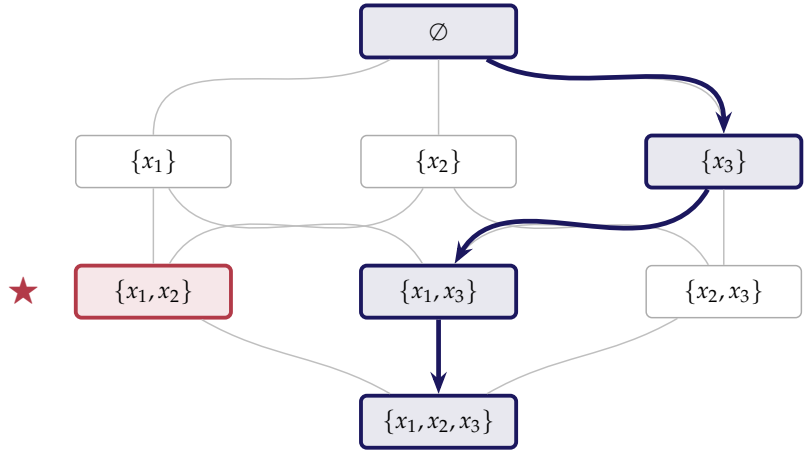
- Por cómputo, la elección del mejor conjunto no se puede aplicar con p grande
- Con p grande también aparecen problemas estadísticos
- Un espacio de búsqueda enorme lleva a sobreajuste y a coeficientes de varianza alta
- Por las dos razones, los métodos por pasos, que exploran un conjunto de modelos mucho más restringido, son una alternativa interesante

Elección por pasos

1. **Hacia adelante** (*forward*)
   - Empezar sin predictores
   - Probar todos los modelos con 1 predictor y quedarse con el mejor
   - Agregar de a un predictor por vez, sin sacar ninguno
   - De los $p + 1$ modelos, elegir el de menor error de predicción con validación cruzada

2. **Hacia atrás** (*backward*)
   - La misma idea, pero arrancando del modelo completo y sacando de a uno

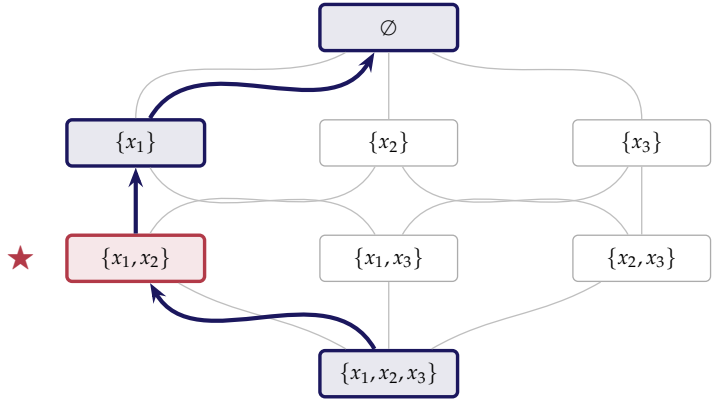
Hacia adelante



★ el mejor par de los tres. *Forward* nunca lo ajusta.

- Una vez que entra x_3, el par $\{x_1, x_2\}$ es **inalcanzable**

Hacia atrás



- Acá **sí** pasa por $\{x_1, x_2\}$: desde el modelo completo mira los tres pares

Cuántos modelos hay que estimar

p	**Mejor conjunto** 2^p	**Por pasos** $1 + p(p+1)/2$
3	8	7
10	1.024	56
20	1.048.576	211
40	1.099.511.627.776	821

Best vs Forward vs Backward

- Se pasa de 2^p modelos a $1 + p(p+1)/2$
- Ninguno de los dos garantiza encontrar el mejor de los 2^p
- *Forward*: una columna que entró, no sale
- *Backward*: una columna que salió, no vuelve. Y exige $n > p$ para poder ajustar el modelo completo
- *Forward* corre con $n < p$
- El anidamiento $\rightarrow$"factibles", pero tambien es su punto debil

Agenda

1. Recap: Predicción y Overfit
2. Out-of-Sample Performance
3. Selección de Modelos Lineales
4. Regularización

El problema fundamental: flexibilidad del modelo

- En regresión, uno de los problemas centrales es decidir qué tan flexible debe ser la función que utilizamos para aproximar la relación entre las variables explicativas X y la variable de respuesta Y.
- Una primera aproximación consiste en escoger una especificación relativamente sencilla:

$$Y = \beta_0 + \beta_1 X + \varepsilon.$$

- Pero también podríamos considerar relaciones más complejas:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \varepsilon.$$

- O incorporar interacciones, splines y otras transformaciones de las variables originales.

Dos decisiones fundamentales

- El problema de especificación plantea dos preguntas diferentes:
  1. ¿Qué funciones deberían estar disponibles para construir nuestro modelo?
  2. ¿Cuánta flexibilidad deberíamos permitir al estimarlo?
- La primera pregunta corresponde a la **construcción del diccionario** de funciones.
- La segunda corresponde al **control de la complejidad** del modelo.
- Esta distinción es el punto de partida para entender métodos como **best subset selection o regularizacion**.

El diccionario de funciones

- Supongamos que construimos un conjunto de funciones candidatas, al que llamaremos nuestro **diccionario**:

$$\mathcal{D} = \{\phi_1(x), \ldots, \phi_p(x)\}.$$

- Estas funciones pueden incluir variables originales, transformaciones, términos polinomiales, interacciones o funciones base de splines.

- Nuestro modelo puede escribirse como:

$$f_\beta(x) = \beta_0 + \sum_{j=1}^{p} \beta_j \phi_j(x).$$

- Aunque el modelo sea **lineal en los parámetros** β_j, no tiene que ser lineal en las variables originales.

El espacio de funciones

- El diccionario determina el espacio de funciones que nuestro modelo puede representar:

$$\mathcal{F}_{\mathcal{D}} = \left\{ f_\beta : \beta \in \mathbb{R}^p \right\}.$$

- **Una limitación fundamental:** la regularización no puede recuperar funciones que no están representadas en el espacio definido por el diccionario.
- Por ejemplo, si únicamente incluimos una función lineal de X, aplicar ridge no permite aprender una relación cuadrática.
- Por esta razón, una estrategia razonable consiste en construir un diccionario suficientemente rico para representar las relaciones que consideramos plausibles.

Flexibilidad potencial y flexibilidad efectiva

- Conviene distinguir dos conceptos diferentes de flexibilidad.
- **Flexibilidad potencial:** corresponde a la riqueza del espacio de funciones generado por el diccionario.
  - Un diccionario con polinomios, interacciones y splines puede representar relaciones más complejas que uno exclusivamente lineal.
- **Flexibilidad efectiva:** corresponde a la capacidad real de la regla de estimación para adaptarse a los datos observados.
- Esta segunda dimensión depende tanto del diccionario como del procedimiento de estimación.
- Podemos tener un diccionario grande y, mediante regularización, construir un estimador relativamente estable.

Una estrategia general de modelación

- La idea central consiste en separar dos decisiones:

$$\text{Diccionario} \longrightarrow \text{Flexibilidad potencial}$$

$$\text{Regularización} \longrightarrow \text{Flexibilidad efectiva}$$

- **Estrategia general:** especificamos un espacio de funciones suficientemente rico y después controlamos su flexibilidad efectiva mediante regularización.
- La palabra *suficientemente* es importante: no se trata de incluir indiscriminadamente todas las transformaciones posibles.
- Un diccionario rico tampoco implica que debamos estimar todos sus coeficientes sin restricciones.

Best subset selection: seleccionar funciones

- Supongamos que tenemos p funciones candidatas en nuestro diccionario.
- **Best subset selection** busca los coeficientes que minimizan el error cuadrático, sujetos a una restricción sobre el número de coeficientes distintos de cero:

$$\hat{\beta}_k = \arg \min_{\beta : \|\beta\|_0 \leq k} \|y - X\beta\|_2^2.$$

- Aquí, $\|\beta\|_0$ cuenta el número de coeficientes no nulos.
- Entre todos los modelos que utilizan como máximo k funciones del diccionario, buscamos el que mejor ajusta los datos de entrenamiento.
- La noción de simplicidad es clara: **un modelo es más simple cuando utiliza menos funciones**.

Best subset selection: problema computacional

- Una búsqueda exhaustiva debe considerar todos los posibles subconjuntos de funciones candidatas.
- Con p funciones, el número total de subconjuntos es:

$$\sum_{k=0}^{p} \binom{p}{k} = 2^p.$$

- Por tanto, el número de modelos candidatos crece exponencialmente con el tamaño del diccionario.
- Para diccionarios grandes, una búsqueda exhaustiva puede ser computacionalmente prohibitiva.
- Existen algoritmos más eficientes que la enumeración exhaustiva, pero la naturaleza combinatoria del problema sigue siendo importante.

Best subset selection: problema estadístico

- Incluso si pudiéramos encontrar instantáneamente el mejor subconjunto, esto no garantizaría la mejor predicción fuera de muestra.
- La búsqueda entre muchos modelos puede seleccionar relaciones accidentales con el ruido, generando problemas de **sobreajuste**.
- Además, el subconjunto seleccionado puede cambiar considerablemente ante pequeñas perturbaciones de los datos, produciendo **inestabilidad**.
- Otro detalle importante: el mejor subconjunto de tamaño k no tiene necesariamente que estar contenido en el mejor subconjunto de tamaño $k+1$.
- Por tanto, **la dificultad de best subset selection no es exclusivamente computacional: también es estadística**.

Agenda

4. Regularización
   - Recap: OLS Mechanics
   - Ridge
   - Lasso
   - $k > n$
   - Ridge and Lasso: Pros and Cons
   - Familia de regresiones penalizadas
   - Elastic Net

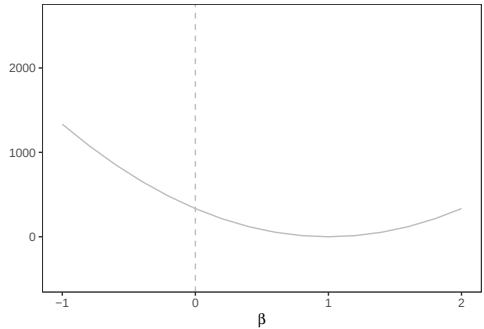
Regularización: Motivación

- OLS minimiza el error *"dentro de muestra"*, eligiendo βs de forma tal que

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 \tag{3}$$

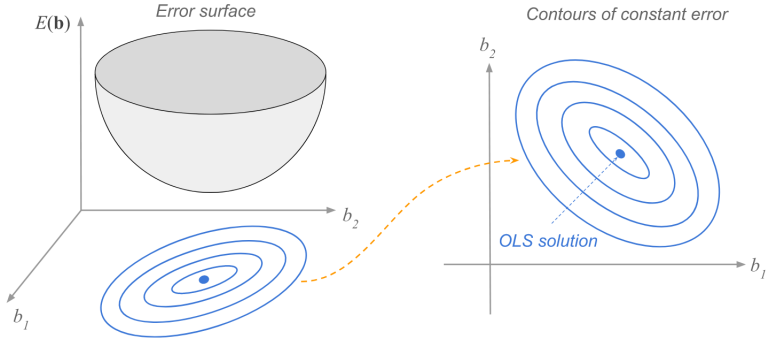
OLS 1 Dimension

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_i \beta)^2 \tag{4}$$



Intuición en 2 Dimensiones (OLS)

$$min_\beta E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \tag{5}$$



Fuente: https://allmodelsarewrong.github.io

Regularización: Motivación

- OLS minimiza el error *"dentro de muestra"*, eligiendo βs de forma tal que

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 \tag{3}$$

- Predicción queremos hacer un buen trabajo **fuera de muestra**

Regularización

- Asegurar cero sesgo dentro de muestra crea problemas fuera de muestra: trade-off Sesgo-Varianza
- Las técnicas de regularizacion hacen este trade-off de forma empírica.
- Vamos a proponer modelos del estilo

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^{p} R(\beta_j) \tag{6}$$

- donde R es un regularizador que penaliza funciones que crean varianza

Agenda

4. Regularización
   - Recap: OLS Mechanics
   - Ridge
   - Lasso
   - $k > n$
   - Ridge and Lasso: Pros and Cons
   - Familia de regresiones penalizadas
   - Elastic Net

Ridge

- Para un $\lambda \geq 0$ dado, consideremos ahora el siguiente problema de optimización

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^{p} (\beta_j)^2 \tag{7}$$

Ridge

- Para un $\lambda \geq 0$ dado, consideremos ahora el siguiente problema de optimización

$$min_\beta E(\beta) = \sum_{i=1}^{n}(y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^{p}(\beta_j)^2 \tag{7}$$

- o en forma matricial

$$min_\beta E(\beta) = (y - X\beta)'(y - X\beta) + \lambda\beta'\beta \tag{8}$$

Ridge: Intuición en 1 Dimension

- 1 predictor estandarizado
- El problema:

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda\beta^2 \tag{9}$$

- La solución?

Intuición en 2 Dimensiones (Ridge)

- En 2 dim

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 + \lambda \left(\beta_1^2 + \beta_2^2\right) \tag{10}$$

- el dual es

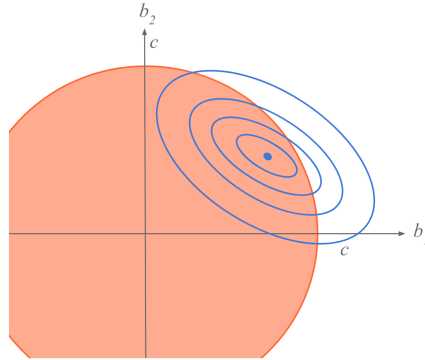
$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \tag{11}$$

sujeto a

$$\left((\beta_1)^2 + (\beta_2)^2\right) \leq c$$

Intuición en 2 Dimensiones (Ridge)

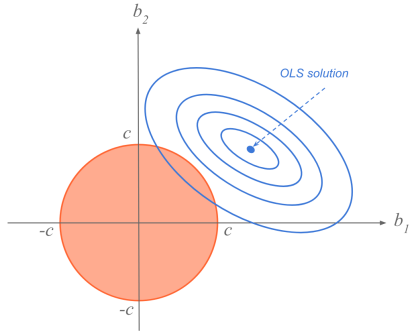
$$min_\beta E(\beta) = \sum_{i=1}^{n}(y_i - x_{i1}\beta_1 - x_{i1}\beta_2)^2 \text{ s.a } \left((\beta_1)^2 + (\beta_2)^2\right) \leq c \tag{12}$$



Fuente: https://allmodelsarewrong.github.io

Intuición en 2 Dimensiones (Ridge)

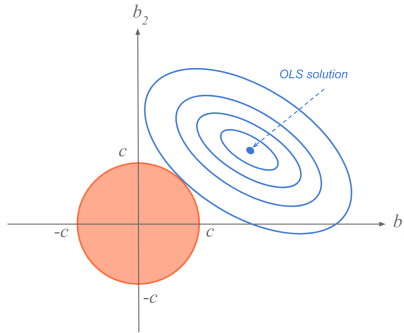
$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i1}\beta_2)^2 \text{ s.a } \left((\beta_1)^2 + (\beta_2)^2\right) \leq c \tag{13}$$



Fuente: https://allmodelsarewrong.github.io

Intuición en 2 Dimensiones (Ridge)

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i1}\beta_2)^2 \text{ s.a } \left((\beta_1)^2 + (\beta_2)^2 \right) \leq c \tag{14}$$



Fuente: https://allmodelsarewrong.github.io

Términos generales

- En regresión multiple (X es una matriz $n \times k$)
- Regresión: $y = X\beta + u$
- OLS

$$\hat{\beta}_{ols} = (X'X)^{-1}X'y$$

- Ridge

$$\hat{\beta}_{ridge} = (X'X + \lambda I)^{-1}X'y$$

Ridge vs OLS

- Ridge es sesgado $E(\hat{\beta}_{ridge}) \neq \beta$
- Pero la varianza es menor que la de OLS
- Para ciertos valores del parámetro $\lambda \Rightarrow MSE_{OLS} > MSE_{ridge}$

Example



photo from https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/

Agenda

4. Regularización
   - Recap: OLS Mechanics
   - Ridge
   - Lasso
   - $k > n$
   - Ridge and Lasso: Pros and Cons
   - Familia de regresiones penalizadas
   - Elastic Net

Lasso

- Para un $\lambda \geq 0$ dado, consideremos el siguiente problema de optimización

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^{p} |\beta_j| \tag{15}$$

- o en forma matricial

$$min_{\beta} E(\beta) = (y - X\beta)'(y - X\beta) + \lambda ||\beta||_1 \tag{16}$$

Lasso Intuición en 1 Dimension

$$min_\beta E(\beta) = \sum_{i=1}^{n}(y_i - x_i\beta)^2 + \lambda|\beta| \tag{17}$$

- Un solo predictor, un solo coeficiente
- Si $\lambda = 0$

$$min_\beta E(\beta) = \sum_{i=1}^{n}(y_i - x_i\beta)^2 \tag{18}$$

- y la solución es

$$\hat{\beta}_{OLS} \tag{19}$$

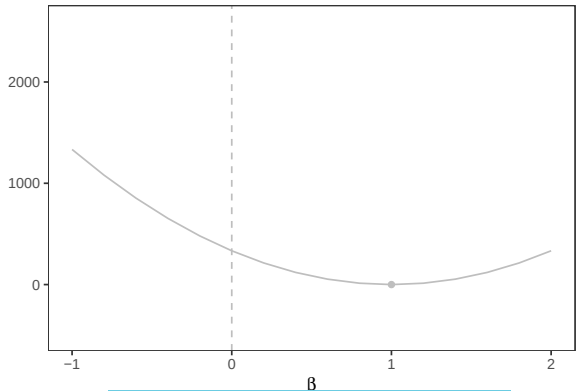
Intuición en 1 Dimension

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda|\beta| \tag{20}$$

Intuición en 1 Dimensión

$\hat{\beta} > 0$

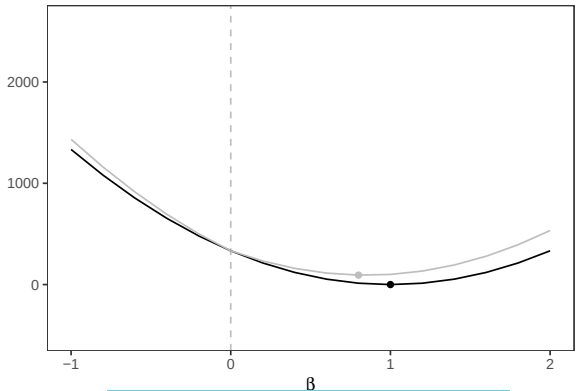
$$min_\beta E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda\beta \tag{21}$$



Intuición en 1 Dimensión

$\hat{\beta} > 0$

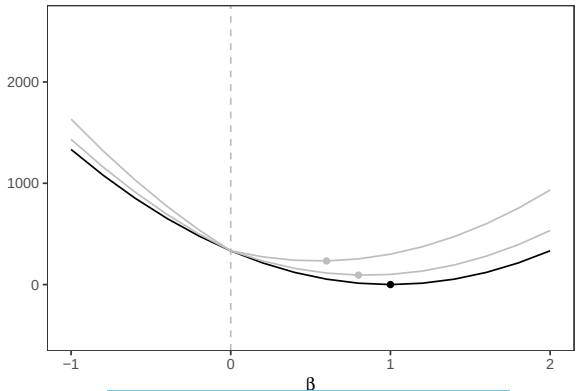
$$min_\beta E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda\beta \tag{22}$$



Intuición en 1 Dimensión

$\hat{\beta} > 0$

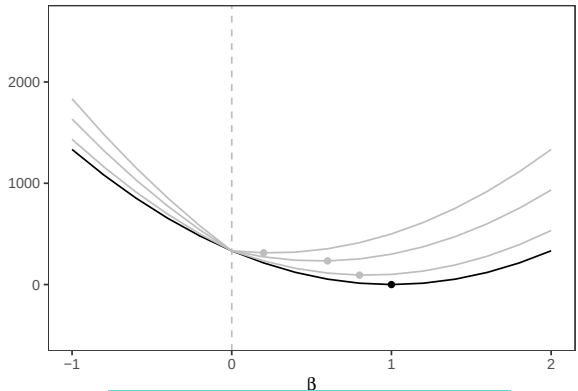
$$min_\beta E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda\beta \tag{23}$$



Intuición en 1 Dimensión

$\hat{\beta} > 0$

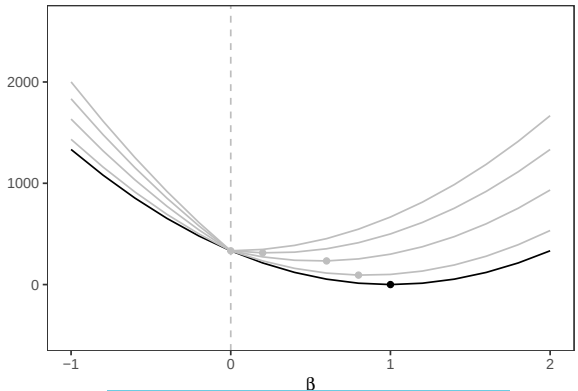
$$min_\beta E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda\beta \tag{24}$$



Intuición en 1 Dimensión

$\hat{\beta} > 0$

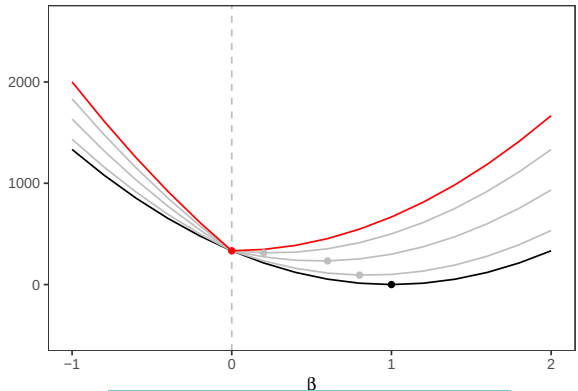
$$min_\beta E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda\beta \tag{25}$$



Intuición en 1 Dimensión

$\hat{\beta} > 0$

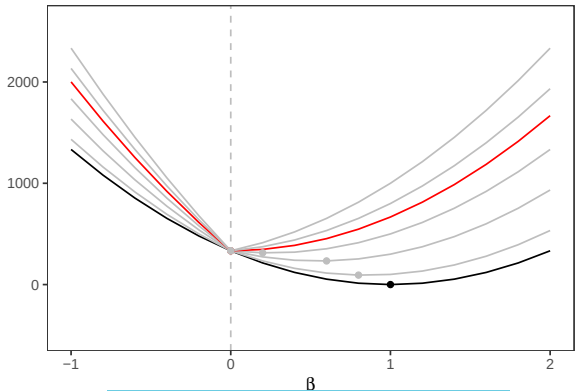
$$min_\beta E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda\beta \tag{26}$$



Intuición en 1 Dimensión

$\hat{\beta} > 0$

$$min_\beta E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda\beta \tag{27}$$



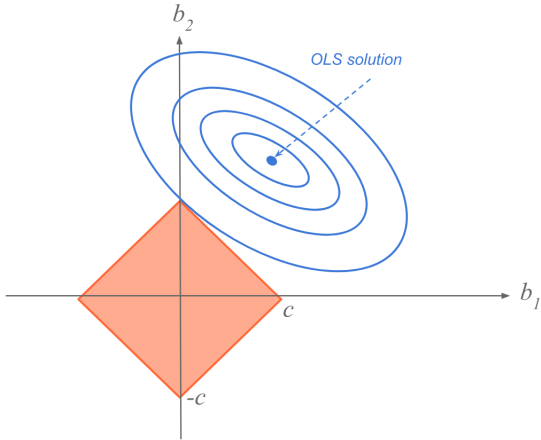
Intuición en 1 Dimension

Solución analitica

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_i\beta)^2 + \lambda|\beta| \tag{28}$$

Intuición en 2 Dimensiones (Lasso)

$$min_{\beta} E(\beta) = \sum_{i=1}^{n} (y_i - x_{i1}\beta_1 - x_{i1}\beta_2)^2 \text{ s.a } (|\beta_1| + |\beta_2|) \leq c \tag{29}$$



Example



photo from https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/

Agenda

4 Regularización
- Recap: OLS Mechanics
- Ridge
- Lasso
- $k > n$
- Ridge and Lasso: Pros and Cons
- Familia de regresiones penalizadas
- Elastic Net

More predictors than observations ($k > n$)

- What happens when we have more predictors than observations ($k > n$)?
  - OLS?
  - Ridge?
  - Lasso?

OLS when $k > n$

- Rank? Max number of rows or columns that are linearly independent
  - Implies $rank(X_{k\times n}) \leq min(k, n)$
- MCO we need $rank(X_{k\times n}) = k \implies k \leq n$
- If $rank(X_{k\times n}) = k$ then $rank(X'X) = k$
- If $k > n$, then $rank(X'X) \leq n < k$ then $(X'X)$ cannot be inverted
- Ridge and Lasso work when $k \geq n$

Ridge when $k > n$

$$min_\beta E(\beta) = \sum_{i=1}^{n}(y_i - x_{i1}\beta_1 - \cdots - x_{ik}\beta_k)^2 + \lambda \sum_{j=1}^{k}(\beta_j)^2 \tag{30}$$

- Solution $\rightarrow$ data augmentation
- Intuition: Ridge "adds" k additional points.
- Allows us to "deal" with $k \geq n$

Ridge when $k > n$

Adding k additional points

Lasso when $k > n$

- In the $k > n$ case, the lasso selects at most n variables before it saturates,
- This is because because of the nature of the convex optimization problem.

Agenda

4 Regularización
- Recap: OLS Mechanics
- Ridge
- Lasso
- $k > n$
- Ridge and Lasso: Pros and Cons
- Familia de regresiones penalizadas
- Elastic Net

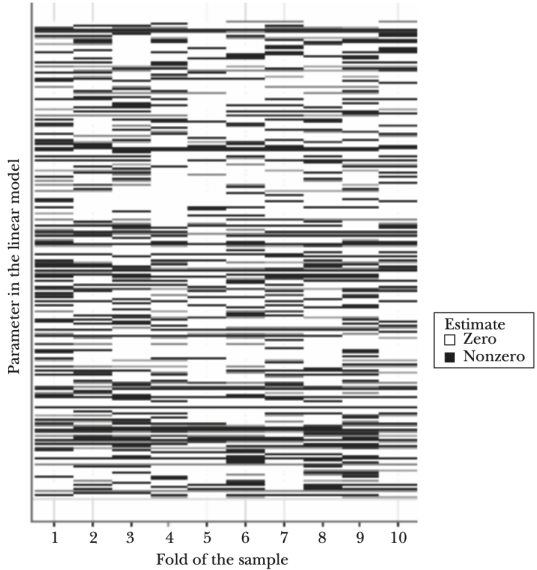
Ridge and Lasso: The good and the bad

- Objective 1: Accuracy
  - Minimize prediction error (in one step) $\rightarrow$ Ridge, Lasso
- Objective 2: Dimensionality
  - Reduce the predictor space $\rightarrow$ Lasso's free lunch
- More predictors than observations ($k > n$)
  - OLS fails
  - Ridge augments data
  - Lasso chooses at most n variables

Ridge and Lasso: The good and the bad

- When we have a group of highly correlated variables,
  - Lasso chooses only one.

Ridge and Lasso: The good and the bad



Ridge and Lasso: The good and the bad

- When we have a group of highly correlated variables,
  - Lasso chooses only one. Makes it unstable for prediction.
  - Ridge shrinks the coefficients of correlated variables toward each other.
  - For usual $n > k$ situations, if there are high correlations between predictors, it has been empirically observed that the prediction performance of the lasso is dominated by ridge regression (Tibshirani, 1996).

Agenda

4. Regularización
   - Recap: OLS Mechanics
   - Ridge
   - Lasso
   - $k > n$
   - Ridge and Lasso: Pros and Cons
   - Familia de regresiones penalizadas
   - Elastic Net

Family of penalized regressions

$$min_{\beta} R(\beta) = \sum_{i=1}^{n} (y_i - x_i'\beta)^2 + \lambda \sum_{s=2}^{p} |\beta_s|^q \tag{31}$$

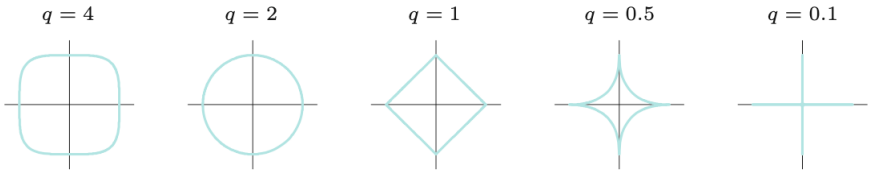


FIGURE 3.12. *Contours of constant value of* $\sum_j |\beta_j|^q$ *for given values of* q.

Agenda

4 Regularización
- Recap: OLS Mechanics
- Ridge
- Lasso
- $k > n$
- Ridge and Lasso: Pros and Cons
- Familia de regresiones penalizadas
- Elastic Net

Elastic Net

- Elastic net: happy medium.
  - Good job at prediction and selecting variables

$$min_{\beta} EN(\beta) = \sum_{i=1}^{n}(y_i - \beta_0 - \sum_{j=1}^{p} x_{ij}\beta_j)^2 + \lambda \left(\alpha \sum_{j=1}^{p} |\beta_j| + \frac{(1-\alpha)}{2} \sum_{j=1}^{p} (\beta_j)^2 \right) \tag{32}$$

- Mixes Ridge and Lasso
- Lasso selects predictors
- Strict convexity part of the penalty (ridge) solves the grouping instability problem
- How to choose (λ, α)? $\rightarrow$ Bidimensional Crossvalidation
- Recomended lecture: Zou, H. & Hastie, T. (2005)

Example



photo from https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/